

## ۱- عنوان: Semantic-Aware Resource Allocation Based on Deep Reinforcement Learning for 5G-V2X HetNets

نویسندگان Zhiyu Shao, Qiong Wu, Pingyi Fan, Niancheng Cheng, Qiang Fan, Jin Wang

نشریه / سال IEEE Communications Letters ۲۰۲۴: (Vol. 28, No. 10, pp. 2452-2456)

IEEE Xplore: <https://doi.org/10.1109/LCOMM.2024.3443603>

ایمپکت فکتور ژورنال: حدود 4-5 برای — (Communications Letters) گزارش‌ها عدد دقیق را ~ ۴.۱-۵.۳۶ نشان می‌دهند.

### خلاصه:

مقدمه: در شبکه‌های ناهمگون V2X نسل ۵، اهمیت پیام‌ها (semantic importance) متفاوت است؛ تخصیص منابع سنتی فاقد این توجه معنایی است.

- مدل سیستم: یک HetNet با گره‌های V2X و منابع رادیویی مشترک؛ هر ترافیک دارای «اهمیت معنایی» است؛ state شامل وضعیت کانال، بار و اهمیت معنایی؛ action تخصیص منابع/تنظیم duty-cycle.
  - روش / الگوریتم: استفاده از DRL مثلاً PPO برای یادگیری سیاست تخصیص منابع با در نظر گرفتن اهمیت معنایی.
  - نتایج کلیدی: در مقایسه با روش‌های بدون semantic، عملکرد بهتری در تحویل پیام‌های مهم، کاهش تأخیر و بهبود استفاده از طیف نشان داده شده است.
- کلمات کلیدی semantic-aware, 5G V2X, deep reinforcement learning, resource allocation, HetNets.

## ۲- عنوان : UniTSA: A Universal Reinforcement Learning Framework for V2X Traffic Signal Control

نویسندگان (چند نفر اول)- Maonan Wang, Xi Xiong, Yuheng Kan, Chengcheng Xu, Man-On Pun

نشریه / سال. *IEEE Transactions on Vehicular Technology*, 2024.

DOI لینک : <https://doi.org/10.1109/TVT.2024.3403879> (IEEE Xplore via DOI)

ایمپکت فکتور (ژورنال) — *IEEE Transactions on Vehicular Technology* : تقریباً 6.1–8.2

مقدمه : هدف کنترل چراغ‌های ترافیک در محیط شهری با استفاده از اطلاعات V2X و RL برای کاهش تراکم و بهبود کارایی شبکه ترافیک. نویسندگان استدلال کرده‌اند که اغلب روش‌های RL قابل تعمیم به تقاطع‌های با ساختارهای مختلف نیستند — بنابراین یک فریم‌ورک «عام» ارائه شده است.

مدل سیستم : تقاطع‌های شهری با خودروهای مجهز به V2X؛ حالت (state) شامل ماتریس ترافیک/حرکت‌ها، عمل = (action) انتخاب فازهای سیگنال/زمان‌بندی؛ محیط پویا و چند-تقاطع.

روش / الگوریتم : چارچوب RL سراسرگیر با طراحی عامل (agent) که از نمایش junction-matrix و روش‌های افزایش داده‌ی مخصوص ترافیک استفاده می‌کند؛ پیاده‌سازی عملی با سیاست‌ها/شبکه‌های عصبی عمیق و ارزیابی در سناریوهای متعدد (مبتنی بر شبیه‌سازی). مفاهیم RL کلاسیک / policy-based — value-based ترکیب شده است.

نتایج کلیدی (خلاصه) : بهبود قابل‌توجه در شاخص‌هایی مثل زمان انتظار میانگین و throughput ترافیک نسبت به baseline های مرسوم؛ عملکرد پایدارتر در تقاطع‌های با ساختار متفاوت — کاربرگ شبیه‌سازی‌ها و کد موجود است. (اعداد دقیق در متن مقاله)

کلمات کلیدی V2X, traffic signal control, reinforcement learning, universal framework, junction matrix

### ۳- عنوان: Reconfigurable Intelligent Surface Assisted VEC Based on Multi-Agent Reinforcement Learning

نویسندگان Kangwei Qi, Qiong Wu, Pingyi Fan, Nan Cheng, Qiang Fan, Jiangzhou Wang

نشریه / سال. *IEEE Communications Letters*, Oct 2024 (Vol. 28, no.10: 2427–2431).

DOI لینک / <https://doi.org/10.1109/LCOMM.2024.3451182>. صفحه / arXiv

preprint هم موجود است .

ایمپکت فکتور (ژورنال) — *IEEE Communications Letters*: همان حدود 4-5~ مراجع تجمیعی مختلف

مقدمه: استفاده از RIS برای افزایش قابلیت ارتباطی در سناریوهای VEC که تحت موانع (ساختمان‌ها) کیفیت کانال را کاهش می‌دهند؛ به دنبال راهکاری برای کنترل هم‌زمان فاز RIS و تصمیمات آفلودینگ/قدرت هستیم .

مدل سیستم: VEC با مجموعه‌ای از vehicles و یک RIS؛ تصمیمات شامل (i): آفلودینگ یا محلی‌سازی، (ii) تخصیص توان، (iii) تنظیم فاز  $RIS.state =$  صف تسک/کانال/قابلیت RIS؛  $action =$  ترکیبی از پارامترهای بالا

روش / الگوریتم: چارچوب DRL مبتنی بر modified MADDPG (multi-agent DDPG) برای بهینه‌سازی تخصیص توان و سیاست آفلودینگ؛ فاز RIS با روش BCD (block coordinate descent) بهینه می‌شود.

نتایج کلیدی: راهکار پیشنهادی بهتر از DDPG متمرکز و از روش‌های تصادفی بوده است — بهبود در نرخ موفق آفلودینگ، تاخیر و بهره‌وری طیف در سناریوهای شبیه‌سازی شده

کلمات کلیدی RIS, vehicular edge computing, MADDPG, multi-agent DRL, resource allocation.

۴- عنوان : Distributed Deep Reinforcement Learning-Based Gradient  
Quantization for Federated Learning Enabled Vehicle Edge Computing

نویسندگان : Cui Zhang, Wenjun Zhang, Qiong Wu, Pingyi Fan, Qiang Fan, Jiangzhou

Wang, Khaled B. Letaief

نشریه / سال) , *IEEE Internet of Things Journal*: مقاله منتشر شده مرتبط با ۲۰۲۵/۲۰۲۴ — رجوع

به (DOI لینک) . <https://doi.org/10.1109/JIOT.2024.3447036>

ایمپکت فکتور (ژورنال) / (JCR'24) ~8.9 — *IEEE Internet of Things Journal*: گزارش‌های ژورنال  
اعلامی ~۸.۹). (مقادیر گوناگون در منابع تجمیعی؛ منبع صفحه رسمی ژورنال عدد ۸.۹ را گزارش می‌دهد  
مقدمه: برای VEC (vehicle edge computing) که از فدریتد لرنینگ استفاده می‌کند، تأخیر و بار ارتباطی  
ناشی از ارسال گرادیان‌ها/آپدیت‌ها مسئله‌ساز است؛ نویسندگان قصد دارند با استفاده از DRL توزیع‌شده، سطح  
کوانتیزه‌سازی گرادیان را تنظیم کنند تا زمان آموزش و خطای کوانتیزه‌سازی بهینه شود.  
مدل سیستم (خیلی خلاصه): مجموعه‌ای از وسایل نقلیه/گره‌ها که با سرور لبه برای FL همکاری می‌کنند؛ هر  
گره می‌تواند سطح کوانتیزه‌سازی را انتخاب کند؛ محیط با شرایط کانال متغیر  $state =$  وضعیت  
کانال/تأخیر/خطای مدل؛  $action =$  سطح کوانتیزه‌سازی/پارامترهای مرتبط  
روش / الگوریتم: چارچوب توزیع‌شده DRL برای یادگیری سیاست کوانتیزه‌سازی گرادیان) به‌صورت هماهنگ با  
هدف کاهش latency و خطا. (ارائه تحلیل همراه اثبات همگرایی جزئی برای الگوریتم پیشنهادی و  
شبیه‌سازی‌های گسترده

نتایج کلیدی: کاهش محسوس در زمان آموزش کلی و در بعضی تنظیمات کاهش خطای فاینال مدل نسبت به  
استراتژی‌های ثابت کوانتیزه‌سازی؛ پایداری بهتر در مواجهه با کانال‌های متغیر

کلمات کلیدی : federated learning, gradient quantization, vehicle edge computing,  
distributed DRL, latency reduction.

## عنوان: Graph Neural Networks and Deep Reinforcement Learning-Based Resource Allocation for V2X Communications

نویسندگان: Maoxin Ji, Qiong Wu, Pingyi Fan, Nan Cheng, Wen Chen, Jiangzhou Wang, Khaled B. Letaief

نشریه / سال IEEE Internet of Things Journal : ۲۰۲۴، DOI: .

<https://doi.org/10.1109/IIOT.2024.3469547>

ایمپکت فکتور: ژورنال IEEE Internet of Things Journal حدوداً 8.9 گزارش شده است.

**مقدمه:** در سیستم‌های V2X (Vehicle-to-Everything) به ویژه با اتصالات V2V و V2I، تخصیص منابع (کانال، توان، زمان‌بندی) بسیار مهم است زیرا محیط بسیار پویا است و هم‌زمان باید تأخیر کم، قابلیت اطمینان بالا و تداخل کم تضمین شود. این مقاله پیشنهاد می‌کند که ترکیب «شبکه عصبی گراف» (GNN) با «یادگیری تقویتی عمیق» (DRL) می‌تواند عملکرد تخصیص منابع را به شکل چشم‌گیری بهبود بخشد.

**مدل سیستم:** ارتباطات C-V2X شامل لینک‌های V2V و V2I؛ محیط به صورت گراف مدل شده است که گره‌ها لینک‌ها یا وسایل هستند و یال‌ها تداخل/ارتباط بین آن‌ها را نمایش می‌دهند. از مدل GraphSAGE برای استخراج ویژگی‌های ساختاری استفاده شده تا عامل (agent) بتواند با مشاهده محلی تصمیم بگیرد.

**روش / الگوریتم:** ابتدا با استفاده از GNN بردار ویژگی از گراف استخراج می‌شود؛ سپس عامل (DRL) مثلاً DQN یا دیگر روش‌های (value-based) با آن کار می‌کند تا سیاست تخصیص منابع را بیاموزد. هدف کاهش تداخل لینک‌های V2I و افزایش نرخ موفق V2V است.

- **نتایج کلیدی:** شبیه‌سازی‌ها نشان می‌دهند که عامل پیشنهادی با ترکیب GNN+DRL نسبت به روش‌های مرسوم تخصیص یکنواخت یا بدون GNN عملکرد بهتری دارد — نرخ تحویل V2V بالاتر، تداخل کمتر، و قابلیت تعمیم بهتر دارد.

کلمات کلیدی

Graph Neural Networks, Deep Reinforcement Learning, Resource Allocation, V2X Communications, C-V2X.